

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное
учреждение высшего образования
**«Южно–Уральский государственный университет
(национальный исследовательский университет)»**
Центр «ВиртУм»

УТВЕРЖДАЮ:

Директор ИЕТН

_____ А.А. Замышляева

_____ 2026 г.

КУРСОВОЙ ПРОЕКТ

по дисциплине «Введение в проектную деятельность»
ЮУрГУ – 09.03.04.2026.306–309.КП

Научный руководитель:

к.ф.–м.н., доцент центра «ВиртУм»

_____ Я.А. Краева

Автор работы:

студент группы ЕТ–141

_____ В.А. Бобыкин

Работа защищена

с оценкой: _____

“ ____ ” _____ 2026 г.

Челябинск, 2026 г.

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное
учреждение высшего образования
**«Южно–Уральский государственный университет
(национальный исследовательский университет)»**
Центр «ВиртУм»

УТВЕРЖДАЮ:

Директор ИЕТН

_____ А.А. Замышляева

«__»._____ 2026 г.

ЗАДАНИЕ

на выполнение курсового проекта

по дисциплине «Введение в проектную деятельность»

студенту группы ЕТ–141

Бобыкину Владиславу Александровичу,

обучающемуся по направлению 09.03.04 «Программная инженерия»

1. Тема проекта

Поиск и первичный анализ наборов данных по различным областям применения

2. Срок сдачи студентом законченной работы: 31.05.2026 г.

3. Исходные данные к работе

3.1. Источник набора табличных данных

3.2. Источник набора данных с временными рядами

3.3. Источник набора данных с изображениями

3.4. Источник набора текстовых данных

4. Перечень подлежащих разработке вопросов

4.1. Подготовить для каждого типа данных (табличные данные, временные ряды, изображения, тексты) краткое описание выбранной задачи, решение которой связано с применением технологий искусственного интеллекта.

4.2. Подобрать для каждого типа данных набор данных из авторитетных открытых источников, необходимый для обучения ИИ–модели, решающей соответствующую выбранную задачу;

4.3. Разработать и реализовать комплекс программ на языке Python, каждая из которых для заданного типа данных должна выполнять следующие основные функции первичного анализа: загрузка и визуализация данных, статистический анализ, выявление специфических особенностей для определенного типа данных.

4.4. Сформулировать выводы по каждому этапу анализа, а также итоговое заключение о качестве данных и их пригодности для решения поставленной задачи.

4.5. Разместить исходный код в репозитории системы контроля версий Git.

5. Дата выдачи задания: 10.03.2026 г.

Научный руководитель

Я.А. Краева

Задание принял к исполнению

В.А. Бобыкин

ОГЛАВЛЕНИЕ

ВВЕДЕНИЕ	5
1. ПЕРВИЧНЫЙ АНАЛИЗ НАБОРА ТАБЛИЧНЫХ ДАННЫХ	8
1.1. Постановка задачи	8
1.2. Описание выбранного набора данных	8
1.3. Описание результатов первичного анализа	10
2. ПЕРВИЧНЫЙ АНАЛИЗ НАБОРА ДАННЫХ С ВРЕМЕННЫМИ РЯДАМИ	26
2.1. Постановка задачи	26
2.2. Описание выбранного набора данных	26
2.3. Описание результатов первичного анализа	27
3. ПЕРВИЧНЫЙ АНАЛИЗ НАБОРА ДАННЫХ С ИЗОБРАЖЕНИЯМИ...	36
3.1. Постановка задачи	36
3.2. Описание выбранного набора данных	36
3.3. Результаты первичного анализа данных с изображениями	39
4. ПЕРВИЧНЫЙ АНАЛИЗ НАБОРА ТЕКСТОВЫХ ДАННЫХ	47
4.1. Постановка задачи	47
4.2. Описание выбранного набора данных	47
4.3. Описание результатов первичного анализа	48
ЗАКЛЮЧЕНИЕ	53
ЛИТЕРАТУРА	54

ВВЕДЕНИЕ

Актуальность

В современном мире технологии искусственного интеллекта (ИИ) и машинного обучения (МО) проникают во все сферы деятельности человека: от медицины [1] и финансов [2] до транспорта [3] и промышленности [4]. Однако успешность применения ИИ–моделей напрямую зависит от качества исходных данных, на которых они обучаются и тестируются.

Как отмечается в исследовании [5], на примере набора данных Telco Customer Churn (7 032 клиента телеком–компании, 19 признаков – стаж, сумма оплат, тип контракта и др., задача – предсказать, уйдет клиент или нет) изучено влияние шести типов дефектов данных на качество прогнозов. Авторы намеренно портили данные: убрали часть значений (неполнота), вносили ошибки в признаки клиентов и в ответы (уйдет/не уйдет), создавали дубликаты, записывали одни и те же значения в разных форматах и нарушали баланс ушедших и оставшихся. Оказалось, что пропуски значений – один из опасных дефектов для модели SVM, поскольку не способен обрабатывать данные с пропусками. Ошибки в ответах (клиент ушел, а в данных записано остался) при 20% неверных меток снижают точность предсказаний на 10%. Ошибки в признаках влияют слабее, особенно на линейные модели. Дубликаты записей почти не мешают, за исключением небольших таблиц. Однако, если модель обучалась на неполных данных, она лучше предсказывает на таких же неполных тестах.

Современные задачи искусственного интеллекта требуют работы с данными различной природы от структурированных таблиц до неструктурированных текстов и изображений. Разнообразие типов данных определяет специфику их анализа и выбор инструментов предварительной обработки.

1. Табличные данные – наиболее распространенный тип, представляющий собой структурированную информацию, организованную в строки (наблюдения) и столбцы (признаки). Форматы представления: CSV,

Excel, SQL–базы данных, Parquet, ARFF. Примеры: данные о клиентах банка, медицинские карты, результаты опросов.

2. Временные ряды – последовательности числовых значений, упорядоченные по времени с фиксированным или переменным шагом. Форматы представления: CSV с временной меткой, NetCDF, TDMS, специализированные форматы (например, EDF для электроэнцефалограмм). Примеры: котировки акций, показания датчиков, метеоданные, физиологические сигналы (ЭКГ, ЭЭГ).

3. Изображения – визуальные данные, представленные в виде матриц пикселей. Форматы представления: JPEG, PNG, BMP, TIFF, а также специализированные медицинские форматы (DICOM, NIfTI). Примеры: фотографии, медицинские снимки (рентген, МРТ, КТ), спутниковые снимки, диаграммы.

4. Текстовые данные – естественно–языковая информация, документы, программный код. Форматы представления: TXT, JSON, XML, CSV (для размеченных текстов), HTML, PDF (после извлечения). Примеры: новостные статьи, посты в социальных сетях, отзывы пользователей, научные публикации, юридические документы.

Таким образом, владение навыками первичного анализа данных разных типов является необходимым для современного специалиста в области искусственного интеллекта. Именно на этапе первичного анализа закладывается фундамент качества всей последующей работы.

Постановка задачи

Целью курсового проекта является получение практических навыков по поиску и первичному анализу наборов данных разных типов по различным областям применения. Для достижения поставленной цели необходимо решить следующие задачи:

1) подготовить для каждого типа данных (табличные данные, временные ряды, изображения, тексты) краткое описание выбранной задачи,

решение которой связано с применением технологий искусственного интеллекта;

2) подобрать для каждого типа данных набор данных из авторитетных открытых источников, необходимый для обучения ИИ–модели, решающей соответствующую выбранную задачу;

3) разработать и реализовать комплекс программ на языке Python, каждая из которых для заданного типа данных должна выполнять следующие основные функции первичного анализа: загрузка и визуализация данных, статистический анализ, выявление специфических особенностей для определенного типа данных;

4) сформулировать выводы по каждому этапу анализа, а также итоговое заключение о качестве данных и их пригодности для решения поставленной задачи;

5) разместить исходный код в репозитории системы контроля версий Git.

Структура и содержание работы

Работа состоит из введения, четырех разделов, заключения и списка литературы. Объем работы составляет 62 страницы, объем списка литературы – 5 источников.

В первом разделе исследуется набор табличных данных Sleep, Screen Time and Stress Analysis.

Второй раздел посвящен анализу набора данных с временными рядами SKAB.

В третьем разделе выполняется анализ набора данных с изображениями Laboro Tomato.

В четвертом разделе представлен анализ набора текстовых данных BBC Full Text Document Classification.

В заключении подводятся итоги курсового проекта.

1. ПЕРВИЧНЫЙ АНАЛИЗ НАБОРА ТАБЛИЧНЫХ ДАННЫХ

1.1. Постановка задачи

Выбранный набор данных Sleep, Screen Time and Stress Analysis предназначен для решения задачи регрессии и классификации в медицине и психологии здоровья.

Задача заключается в прогнозировании уровня стресса, качества сна и умственной усталости на основе поведенческих факторов: возраста, пола, профессии, ежедневном экранном времени, использовании телефона перед сном, потреблении кофеина, физической активности, количестве уведомлений в день;

Предметной областью задачи выступает медицина и психология здоровья;

Практическая значимость работы включает раннее выявление лиц, подверженных хроническому стрессу, разработку рекомендательных систем для улучшения качества сна, создание корпоративных программ здоровья сотрудников, а также интеграцию в мобильные приложения для мониторинга психоэмоционального состояния;

Основными требованиями к данным являются объем выборки не менее 500 записей, наличие целевых признаков, разнообразие категориальных переменных, отсутствие значительного числа пропусков.

1.2. Описание выбранного набора данных

Набор данных имеет название Sleep, Screen Time and Stress Analysis. Ссылка на источник: <https://www.kaggle.com/datasets/jayjoshi37/sleep-screen-time-and-stress-analysis>. Автором является Jay Joshi. Данные имеют синтетическую природу, то есть они были искусственно сгенерированы в марте 2026 года для исследовательских целей. Разметка целевых признаков выполнялась автоматически в процессе генерации данных. Выбор именно этого набора обоснован несколькими причинами

- Выборка содержит пятнадцать тысяч записей, что является достаточным объемом.

- Присутствуют три целевых признака, напрямую связанных с психоэмоциональным состоянием человека.

- Входные признаки разнообразны и включают как числовые, так и категориальные переменные.

- Полностью отсутствуют пропуски.

- Категориальные признаки, такие как пол и профессии, хорошо сбалансированы.

Структура данных включает 15 000 записей, и тринадцать признаков, три из которых являются целевыми. В табл. 1 приведен перечень признаков и их краткое описание.

Таблица 1. Перечень всех признаков


№	Признак	Тип данных	Семантика	Диапазон значений	Пример
1	user_id	int64	Уникальный идентификатор пользователя	[1, 15000]	1
2	age	int64	Возраст в годах	[18, 59]	56
3	gender	object	Пол	Female, Male, Other	Female
4	occupation	object	Род занятий (профессия)	8 уникальных значений	Designer
5	daily_screen_time_hours	float64	Ежедневное время перед экраном (часы)	[1.00, 10.00]	3.26
6	phone_usage_before_sleep_minutes	int64	Использование телефона перед сном (минуты)	[0, 119]	86
7	sleep_duration_hours	float64	Длительность сна (часы)	[4.00, 9.00]	5.31
8	sleep_quality_score	float64	Оценка качества сна (шкала от 1 до 10)	[1.00, 10.00]	7.72
9	stress_level	float64	Уровень стресса (шкала от 1 до 10)	[1.00, 10.00]	3.49
10	caffeine_intake_cups	int64	Потребление кофеина (чашек в день)	[0, 4]	0
11	physical_activity_minutes	int64	Физическая активность (минуты в день)	[0, 119]	35
12	notifications_receive_per_day	int64	Количество полученных уведомлений за день	[20, 299]	119
13	mental_fatigue_score	float64	Уровень умственной усталости (шкала от 1 до 10)	[1.00, 10.00]	3.57

Вопросов чувствительности и конфиденциальности не возникает, поскольку данные синтетические и не содержат персональной информации. Признак `user_id` представляет собой обезличенный числовой идентификатор, поэтому набор данных может использоваться без дополнительных ограничений.

1.3. Описание результатов первичного анализа

1.3.1. Визуализация распределения признаков

На рис. 1 представлены гистограммы распределения значений для всех числовых признаков табличного набора данных «Sleep, Screen Time and Stress Analysis».






Рисунок 1. Гистограммы распределения числовых признаков

На основе рисунка 1 можно сделать следующие выводы:

- Анализ распределения признака `age` (возраст) показывает распределение, близкое к поперечному распределению, с пиком в диапазоне от 30 до 35 лет.
- Распределение признака `daily_screen_time_hours` (экранное время), `sleep_duration_hours` (длительность сна), `phone_usage_before_sleep_minutes` (использование телефона перед сном) характеризуется равномерностью. Такое распределение может быть связано с особенностями синтетической генерации данных.
- `sleep_quality_score` (качество сна, целевой). Распределение близко к нормальному с пиком в диапазоне от 5 до 7 (из 10). Небольшое смещение в сторону высоких значений указывает на то, что в выборке преобладают респонденты с хорошим качеством сна.
- Распределение целевого признака `stress_level` (уровень стресса) смещено в сторону высоких значений. Это указывает на преобладание повышенного стресса в выборке и может быть связано с особенностями синтетической генерации данных.
- Признак `caffeine_intake_cups` (потребление кофеина) демонстрирует дискретное распределение с пиками на 0, 1, 2, 3 и 4 чашки.

- Признак `physical_activity_minutes` (физическая активность), `notifications_received_per_day` (количество уведомлений) имеет равномерное распределение.
- `mental_fatigue_score` (умственная усталость, целевой). Распределение коррелирует с уровнем стресса, смещено в сторону повышенных значений (пик в диапазоне от 9 до 10).
- Все числовые признаки находятся в реалистичных диапазонах значений, выбросы присутствуют (подробнее в п. 1.3.6).

На рис. 2 представлены диаграммы распределения категориальных признаков.




Рисунок 2. Диаграммы распределения категориальных признаков

Анализ категориальных признаков показывает, что распределение по полу сбалансировано (Male – 48%, Female – 48%, Other – 4%). Признак `occupation` (профессия) включает 8 категорий, распределение которых является равномерным: каждая профессия насчитывает около 1800 записей. Редкие категории отсутствуют, что позволяет использовать все категории для анализа без агрегации.

1.3.2. Визуализация признаков

На рис. 3 представлены графики визуализации отдельных признаков и их пар с использованием библиотеки Seaborn.






Рисунок 3. Визуализация признаков (Seaborn)

График 1. Экранное время – Качество сна. На графике каждая точка соответствует одному респонденту. По оси X отложено ежедневное экранное время, по оси Y – качество сна (шкала от 1 до 10). Точки сгруппированы таким образом, что при увеличении экранного времени значения качества сна смещаются вниз, что указывает на отрицательную связь между признаками.

График 2. Стресс – Умственная усталость. На графике показана зависимость между уровнем стресса и умственной усталостью. Наблюдается положительная корреляция: при повышении уровня стресса растет и уровень умственной усталости. Линия регрессии идет вверх, что логически обосновано: стресс истощает когнитивные ресурсы.

График 3. Физическая активность – Качество сна. На графике показана зависимость между физической активностью и качеством сна. Линия регрессии не имеет выраженного наклона, что свидетельствует о нейтральной корреляции – физическая активность и качество сна в данном наборе данных статистически значимо не влияют друг на друга. Это может быть связано с особенностями синтетической генерации данных.

На рис. 4 представлены интерактивные графики, построенные с использованием библиотеки Plotly. Интерактивные графики позволяют наводить курсор на точки для просмотра точных значений, масштабировать области и скрывать категории.

График 1 Экранное время – Качество сна. На графике при увеличении экранного времени значения качества сна смещаются вниз, что указывает на отрицательную связь между признаками.

График 2. Стресс – Умственная усталость. На графике наблюдается положительная корреляция: при повышении уровня стресса растет и уровень умственной усталости.



Рисунок 4. Интерактивная визуализация признаков (Plotly)

1.3.3. Анализ на наличие пропусков в данных и устранение дубликатов строк

В результате проверки на наличие пропусков и дубликатов в наборе данных. Было выявлено, что все признаки набора данных не содержат пропущенных значений и дубликатов строк. Это указывает на то, что синтетически сгенерированные данные имеют высокое качество.

Отсутствие пропусков и дубликатов позволяет использовать все записи для дальнейшего анализа и построения модели без применения методов восстановления данных.

1.3.4. Корреляционный анализ

Для оценки силы и направления взаимосвязей между числовыми признаками был проведен корреляционный анализ с вычислением

коэффициента корреляции Пирсона. На рис. 5 представлена тепловая карта корреляций.




Рисунок 5. Тепловая карта корреляций числовых признаков

На основе рис. 5 можно выделить следующие наиболее сильные корреляционные связи:

- Положительные корреляции: stress_level и mental_fatigue_score – коэффициент корреляции +0,95.
- Отрицательные корреляции: stress_level и sleep_quality_score – коэффициент –0,86. daily_screen_time_hours и sleep_quality_score – коэффициент –0,75.
- Слабые корреляции: все остальные.




Рисунок 6. Влияние признаков на уровень стресса (отсортировано)

На основе рис. 6 можно выделить следующие наиболее сильные корреляционные связи:

- Наибольшее положительное влияние на уровень стресса оказывает `mental_fatigue_score` (+0.95).
- Наибольшее отрицательное влияние – `sleep_quality_score` (–0.86).
- Признаки `age` и `notifications_received_per_day` и другие практически не влияют на уровень стресса (коэффициенты близки к 0).

Выводы по корреляционному анализу: Обнаружена сильная мультиколлинеарность между целевыми признаками `stress_level` и `mental_fatigue_score` (0.95), что не является проблемой для обучения модели, так как эти признаки не подаются на вход модели. Корреляции между входными признаками не превышают 0.75, что свидетельствует об отсутствии мультиколлинеарности. Следовательно, данные могут использоваться для обучения большинства алгоритмов машинного обучения без дополнительной обработки.

1.3.5. Анализ и обработка выбросов

Для выявления нетипичных значений (выбросов) в числовых признаках были построены boxplot-диаграммы. На рис. 7 представлены boxplot-диаграммы для всех числовых признаков набора данных.




Рисунок 7. Boxplot-диаграммы для выявления выбросов

На рис. 8 представлены boxplot–диаграммы для всех числовых признаков набора данных с единой шкалой.




Рисунок 8. Boxplot–диаграммы с единой шкалой

Анализ выбросов: в табл. 2 приведены результаты проверки каждого числового признака на наличие выбросов.

Таблица 2. Результаты анализа выбросов по признакам

Признак	Наличие выбросов	Количество выбросов
age	Нет	0
daily_screen_time_hours	Нет	0
phone_usage_before_sleep_minutes	Нет	0
sleep_duration_hours	Нет	0
sleep_quality_score	Да	9
stress_level	Нет	0
caffeine_intake_cups	Нет	0
physical_activity_minutes	Нет	0
notifications_received_per_day	Нет	0
mental_fatigue_score	Нет	0

Можно видеть, что выбросы обнаружены только в одном признаке – sleep_quality_score (качество сна). На boxplot–диаграмме для этого признака присутствуют точки ниже нижнего «уса» (красные кружки), что соответствует значениям качества сна 1–2 балла. Эти наблюдения указывают на очень плохое качество сна у небольшой группы респондентов – экстремальные случаи. Все остальные числовые признаки не содержат выбросов – их

значения находятся в пределах нормального диапазона (между верхним и нижним «усами»). Поскольку выбросы обнаружены только в одном признаке и их количество невелико можем оставить их без изменений.

1.3.6. Кодирование категориальных признаков

Так как большинство алгоритмов машинного обучения работают только с числовыми данными, категориальные признаки необходимо преобразовать в числовой формат. В данном наборе данных категориальными признаками являются gender (пол) и occupation (профессия). Для их преобразования был применен метод Label Encoding с использованием класса LabelEncoder из библиотеки scikit-learn.

Метод заключается в том, чтобы каждой категории присвоить целочисленное значение (0, 1, 2, ...). Метод не увеличивает размерность данных, в отличие от One-Hot Encoding, который создает отдельную бинарную строку (001, 010, 100) для каждого уникального значения.

В табл. 3 и 4 представлено соответствие категорий числовым меткам для признаков gender и occupation.

Таблица 3. Соответствие категорий числам для признака gender

Исходная категория	Числовая метка
Female	0
Male	1
Other	2

Таблица 4. Соответствие категорий числам для признака occupation

Исходная категория	Числовая метка
Designer	0
Researcher	1
Freelancer	2
Manager	3
Doctor	4
Software Engineer	5
Student	6
Teacher	7

1.3.8 Анализ диапазонов значений признаков

Различные признаки в наборе данных измеряются в разных единицах и имеют существенно различающиеся масштабы. Многие алгоритмы машинного обучения (нейронные сети) чувствительны к масштабу признаков и будут неявно придавать больший вес признакам с большими числовыми значениями, что может исказить результаты моделирования. Данный этап направлен на выявление таких различий для принятия решения о необходимости стандартизации данных.

В табл. 5 приведены минимальные и максимальные значения, а также разница для каждого числового признака.

Таблица 5. Диапазоны значений числовых признаков

Признак	Минимум	Максимум	Разница
age	18	59	41
daily_screen_time_hours	1,00	10,00	9,00
phone_usage_before_sleep_minutes	0	119	119
sleep_duration_hours	4,00	9,00	5,00
sleep_quality_score	1,00	10,00	9,00
stress_level	1,00	10,00	9,00
caffeine_intake_cups	0	4	4
physical_activity_minutes	0	119	119
notifications_received_per_day	20	299	279
mental_fatigue_score	1,00	10,00	9,00

На основе табл. 5 можно сделать следующие выводы:

1. Значительное различие в масштабах. Признак `notifications_received_per_day` имеет разницу 279 единиц, в то время как `caffeine_intake_cups` – всего 4 единицы. Различие в масштабах достигает 70 раз, что является существенным.

2. Разные единицы измерения. Признаки измеряются в разных единицах: возраст – в годах, время – в часах и минутах, балльные оценки – по шкале 1–10, количество – в штуках. Прямое сравнение числовых значений таких признаков некорректно без приведения к единому масштабу.

3. Отсутствие аномальных диапазонов. Все признаки находятся в разумных пределах, соответствующих их физическому смыслу. Ни один признак не выходит за границы допустимых значений, указанных в описании набора данных.

1.3.9. Фильтрация данных

Для демонстрации возможностей работы с данными были выполнены три условные фильтрации сэмплов. В табл. 6 представлены условия фильтрации и количество отобранных записей.

Таблица 6. Результаты условной фильтрации

№	Условие фильтрации	Количество записей
1	stress_level > 7 И sleep_quality_score < 5 (высокий стресс + плохой сон)	3697
2	daily_screen_time_hours > 8 И physical_activity_minutes < 30 (высокое значение экранного времени + низкая активность)	866
3	age <= 18 И caffeine_intake_cups > 3 (молодые люди с высоким потреблением кофеина)	71

Все три фильтра демонстрируют возможность гибкой выборки данных по заданным критериям с использованием логических операций «И» (&) для комбинирования условий.

1.3.10. Добавление шума

С целью проверки устойчивости моделей машинного обучения к искажениям входных данных и имитации реальных ошибок измерений в два числовых признака (исключая целевые) был добавлен искусственный шум. В табл. 7 приведено описание добавленных шумов.

Таблица 7. Характеристики добавленного шума

Признак	Тип шума	Параметры	Цель добавления
daily_screen_time_hours	Гауссовский (нормальный)	$\mu = 0, \sigma = 0,5$	Имитация случайных ошибок при измерении времени
physical_activity_minutes	Равномерный	$[-5, +5]$ минут	Имитация вариативности дневной активности




Рисунок 9. Влияние добавления шума на распределение признаков

На основе рис. 9 можно сделать следующие выводы.

Для признака `daily_screen_time_hours` (экранное время): после добавления гауссовского шума гистограмма стала более «размытой» – границы столбцов сгладились, появились промежуточные значения. Однако общая форма распределения сохранилась, среднее значение практически не изменилось.

Для признака `physical_activity_minutes` (физическая активность): после добавления равномерного шума распределение также стало более плавным, без появления новых значимых пиков.

Потенциальная ценность добавления шума: позволяет оценить, насколько устойчивы алгоритмы машинного обучения к небольшим неточностям во входных данных.

Имитация реальных условий. В реальных прикладных задачах данные практически всегда содержат погрешности измерений, и модель должна корректно работать в таких условиях.

Предотвращение переобучения. Обучение на данных с добавленным небольшим шумом может повысить обобщающую способность модели и снизить риск переобучения.

Аугментация данных. Искусственное добавление шума увеличивает эффективный объем обучающей выборки без сбора дополнительных реальных данных.

Выводы по первому разделу

В результате первичного анализа набора табличных данных «Sleep, Screen Time and Stress Analysis» получены следующие выводы.

Объем выборки 15 000 записей, количество признаков 13 (10 числовых, 3 категориальных), целевые признаки: `stress_level`, `sleep_quality_score`, `mental_fatigue_score`, источником является открытый репозиторий Kaggle (автор Jay Joshi), данные синтетические.

Таблица 8. Выявленные проблемы в данных

Параметр	Результат
Пропущенные значения	Отсутствуют
Дубликаты	Отсутствуют
Выбросы	Присутствуют только в признаке <code>sleep_quality_score</code> (единичные)
Дисбаланс классов	Отсутствует (категории сбалансированы)
Корреляции	Выявлены логически обоснованные связи (стресс–усталость, экранное время–качество сна)

Набор данных полностью пригоден для решения задачи прогнозирования уровня стресса, качества сна и умственной усталости. Благодаря отсутствию пропусков и дубликатов, а также минимальному количеству выбросов, данные не требуют трудоемкой предварительной очистки. Сбалансированность категориальных признаков и разнообразие числовых признаков обеспечивают возможность построения качественных моделей машинного обучения. Однако синтетическая природа данных

накладывает ограничения на возможность переноса результатов на реальные данные.

Рекомендации по предварительной обработке перед построением модели:

- Масштабирование числовых признаков. Рекомендуется применить стандартизацию (StandardScaler) для приведения всех числовых признаков к единому масштабу.
- Кодирование категориальных признаков. Для признака gender использовать Label Encoding. Для признака occupation (10 категорий) – One–Hot Encoding.
- Обработка выбросов. Единичные выбросы в признаке sleep_quality_score можно удалить (не более 0,1% выборки) или оставить для анализа экстремальных случаев.
- Разделение выборки. Перед обучением модели разделить данные на обучающую (70%), валидационную (15%) и тестовую (15%) выборки.
- Отбор признаков. На основании корреляционного анализа наиболее значимыми для прогнозирования являются: daily_screen_time_hours, physical_activity_minutes, caffeine_intake_cups, mental_fatigue_score.

2. ПЕРВИЧНЫЙ АНАЛИЗ НАБОРА ДАННЫХ С ВРЕМЕННЫМИ РЯДАМИ

2.1. Постановка задачи

Выбранный набор данных SKAB (Skoltech Anomaly Benchmark) предназначен для решения задачи поиска аномалий в промышленном оборудовании.

Задача заключается в обнаружении аномалий (точечных выбросов и коллективных изменений режима) в работе насосной системы на основе показаний датчиков.

Входными данными являются показания восьми датчиков: вибрация (2 акселерометра), ток, давление, температура двигателя, температура жидкости (термопара), напряжение, скорость потока.

Выходными данными (целевыми признаками) выступают бинарные метки: anomaly – точечная аномалия (0/1), changepoint – смена режима (0/1).

Предметной областью является промышленная диагностика и предиктивное обслуживание насосного оборудования.

Практическая значимость включает раннее выявление неисправностей, предотвращение аварий, сокращение времени простоя оборудования.

2.2. Описание выбранного набора данных

Название набора данных SKAB (Skoltech Anomaly Benchmark) v0.9. Ссылка: <https://www.kaggle.com/datasets/yuriykatser/skoltech-anomaly-benchmark-skab>. Авторами являются Iurii D. Katser, Vyacheslav O. Kozitsin (Сколковский институт науки и технологий), 2020 г. Данные реальные, собраны с испытательного стенда насосной системы. Разметка аномалий выполнена вручную на основе контролируемых воздействий (закрытие клапанов, дисбаланс ротора, кавитация). Данный датасет был выбран, поскольку имеет двойную разметку (точечные и коллективные аномалии), многомерный (8 каналов), достаточный объем, открытую лицензию CC0.

Состоит из 35 CSV-файлов (экспериментов), 46 860 строк, 12 столбцов (datetime, 8 измерительных каналов, experiment, anomaly, changepoint).

В табл. 9 приведен перечень всех признаков.

Таблица 9. Перечень всех признаков и их описание

№	Канал	Тип	Ед. изм.	Семантика
1	Accelerometer1RMS	float64	g	Виброускорение, датчик 1
2	Accelerometer2RMS	float64	g	Виброускорение, датчик 2
3	Current	float64	A	Ток электродвигателя
4	Pressure	float64	бар	Давление после насоса
5	Temperature	float64	°C	Температура корпуса двигателя
6	Thermocouple	float64	°C	Температура жидкости в контуре
7	Voltage	float64	B	Напряжение на двигателе
8	Volume Flow RateRMS	float64	л/мин	Скорость потока жидкости
9	anomaly	float64	0/1	Метка точечной аномалии
10	changepoint	float64	0/1	Метка смены режима

2.3. Описание результатов первичного анализа

2.3.1. Загрузка и первичное знакомство

Данные загружены из 35 CSV–файлов. Столбец datetime преобразован в формат datetime и установлен в качестве индекса. Общий объем: 46 860 строк, 8 измерительных каналов. Временная метка присутствует в формате YYYY–MM–DD hh:mm:ss. Все каналы имеют числовой тип float64. Структура соответствует описанию датасета, загрузка выполнена без ошибок.

2.3.2. Визуализация исходных данных

Для детальной визуализации выбран эксперимент 1 (2208 точек, 735 аномалий, 8 changepoint, период 6 часов).

На рис. 10 представлены графики всех каналов с выделением аномалий красным цветом.




Рисунок 10. Визуализация графиков всех каналов с выделением аномалий

На рис. 11 – представлен отдельно канал Temperature с разметкой.




Рисунок 11. Визуализация канала Temperature

Выводы:

- Размеченные аномалии визуально совпадают с резкими скачками на графиках.
- Присутствуют точечные аномалии (отдельные выбросы) и коллективные (группы точек).
- Каналы взаимосвязаны (Current, Voltage, Pressure меняются синхронно).
- Видны повторяющиеся циклы работы насоса.
- Разрывов и пропусков на графиках не обнаружено.

2.3.3. Статистический анализ

Для количественной оценки характеристик многомерного временного ряда рассчитаны описательные статистики по каждому из восьми измерительных каналов. Результаты представлены в табл. 10.

Таблица 10. Описательные статистики измерительных каналов

Канал	count	mean	std	min	Q1 (25%)	Q2 (50%)	Q3 (75%)	max
Accelerometer1RMS	46860	0,130	0,1261	0,0000	0,027	0,0804	0,215	0,722
Accelerometer2RMS	46860	0,163	0,1442	0,0000	0,040	0,130	0,268	0,800
Current	46860	1,834	6,333	0,355	0,983	1,376	2,484	243,829
Pressure	46860	0,080	0,259	-1,257	0,054	0,054	0,382	1,694
Temperature	46860	79,361	9,404	65,089	69,511	84,975	88,620	95,011
Thermocouple	46860	26,576	2,539	22,020	24,650	25,609	29,157	33,415
Voltage	46860	229,398	12,677	0,580	223,545	229,845	235,923	255,324
Volume Flow RateRMS	46860	75,267	45,839	0,000	32,000	72,021	126,000	133,688

Выводы по статистическому анализу:

1. Асимметрия распределений. В каналах Accelerometer1RMS, Accelerometer2RMS, Current, Pressure среднее значение существенно отличается от медианы (например, Current: среднее 1,83 А, медиана 1,38 А). Это свидетельствует о правосторонней асимметрии: насос большую часть времени выключен (значения близки к нулю), а при включении возникают кратковременные пиковые нагрузки. Распределение Voltage близко к симметричному (среднее 229,40 В, медиана 229,85 В).

2. Разброс значений. Коэффициент вариации ($CV = \text{std} / \text{mean} \times 100\%$) варьируется от 5,5% (Voltage) до 345,3% (Current). Различие в 63 раза

указывает на необходимость стандартизации данных перед применением моделей, чувствительных к масштабу признаков.

3. Каналы с околонулевой дисперсией отсутствуют. Все восемь каналов несут полезную информацию.

2.3.4. Анализ пропусков и выбросов

Пропуски: в измерительных каналах отсутствуют (0 из 374 880 значений). Столбцы anomaly и changepoint содержали NaN (отсутствие аномалии), заменены на 0.

В табл. 11 представлены кол-во выбросов (правило 3σ):

Таблица 11. Количество выбросов по каналам (правило 3σ)

Канал	Выбросов	Доля, %
Accelerometer1RMS	1253	2,67
Accelerometer2RMS	1227	2,62
Current	36	0,08
Pressure	65	0,14
Temperature	0	0,00
Thermocouple	0	0,00
Voltage	37	0,08
Volume Flow RateRMS	0	0,00

На рис. 12 представлены boxplot-диаграммы, подтверждающие концентрацию значений вблизи нуля.




Рисунок 12. boxplot-диаграммы

1. Пропуски в измерительных каналах отсутствуют (0 из 374 880). NaN в столбцах anomaly и changepoint заменены на 0.

2. Выбросы (правило 3σ): Accelerometer1RMS – 1253 (2,67%), Accelerometer2RMS – 1227 (2,62%), Current – 36 (0,08%), Pressure – 65 (0,14%), Voltage – 37 (0,08%), остальные – 0. Выбросы = целевые аномалии, удалять нельзя.

3. Temperature, Thermocouple, Volume Flow RateRMS – стабильные каналы без выбросов.

4. Рекомендации: выбросы сохранить, применить StandardScaler.

2.3.5. Анализ диапазонов значений

Каналы измеряются в разных единицах (g, A, бар, °C, В, л/мин). Размах значений: от 0,722 (Accelerometer1RMS) до 254,74 (Voltage) – отношение 352:1.

На рис. 13 представлена общая диаграмма размаха.




Рисунок 13. boxplot–диаграммы (с нормализацией)

Выводы по анализу диапазонов:

1. Значительное различие в масштабах. Размах значений составляет от 0,722 (Accelerometer1RMS) до 254,74 (Voltage). Отношение максимального размаха к минимальному – 352:1. Столь сильное различие неизбежно приведет к доминированию каналов с большими числовыми значениями при использовании методов, чувствительных к масштабу.

2. Разные единицы измерения. Каналы измеряются в принципиально разных единицах (g, A, бар, °C, В, л/мин), что делает прямое сравнение числовых значений некорректным.

3. Необходимость стандартизации. Для алгоритмов, чувствительных к масштабу (нейронные сети), требуется обязательная стандартизация (StandardScaler). Для алгоритмов на основе деревьев решений масштабирование не является критичным, однако его применение обеспечит единообразие обработки.

2.3.6. Корреляционный анализ

Матрица корреляций Пирсона представлена на рис. 14.




Рисунок 14. Тепловая карта корреляций измерительных каналов

Сильные корреляции ($|r| > 0,7$): Accelerometer1RMS – Accelerometer2RMS: $r = 0,996$, Accelerometer2RMS – Volume Flow RateRMS: $r = 0,83$, Temperature – Volume Flow RateRMS: $r = 0,90$. Всего 9 пар с сильной положительной связью.

Слабые отрицательные корреляции: Voltage со всеми признаками.

Уникальный канал: Pressure (макс. $|r| = 0,11$ со всеми). Несет независимую информацию.

Обнаружено 9 пар с сильной положительной корреляцией ($r > 0,7$). Каналы Accelerometer1RMS и Accelerometer2RMS практически дублируют друг друга ($r = 0,996$) – один можно исключить. Слабые отрицательные корреляции: Voltage – Current ($r = -0,079$), Voltage – Volume Flow RateRMS ($r = -0,086$). Канал Pressure слабо связан с остальными ($|r| < 0,11$) и несет уникальную информацию.

2.3.7. Поиск и анализ шумов

Декомпозиция канала Temperature (эксперимент 1) выполнена с периодом 60 сек. Результаты представлены на рис. 15.




Рисунок 15. Декомпозиция канала Temperature – эксперимент 1

Характеристики:

- Тренд: падающий (изменение на $-8,17^{\circ}\text{C}$ за 6 часов), интенсивность сильная – отражает остывание двигателя.
- Сезонность: период ~ 60 сек, амплитуда низкая ($0,20^{\circ}\text{C}$) – циклы включения/выключения.
- $\text{SNR} = 21,11$ дБ – качество «Отлично», шум практически незаметен.
- Распределение остатков близко к нормальному (рис. 16), шум случаен, декомпозиция адекватна.




Рисунок 16. Гистограмма распределения остатков (шума)

Вывод по поиску и анализу шумов:

$SNR = 21,11$ дБ (Отлично) – шум практически незаметен, данные очень чистые. Распределение остатков близко к нормальному – декомпозиция адекватна, шум случаен. Фильтрация данных не требуется.

Выводы по второму разделу

В результате первичного анализа набора с временными рядами «SKAB» получены следующие выводы:

Результаты анализа, представлены в табл. 12.

Таблица 12. Сводные результаты анализа набора SKAB

Параметр	Результат
Объем	46 860 строк, 8 каналов
Частота	1 Гц
Пропуски	Отсутствуют
Выбросы	Присутствуют (целевые аномалии)
Корреляции	9 пар с $r > 0,7$
SNR	21,11 дБ (Отлично)

Данные полностью пригодны для задачи поиска аномалий.

Наличие двойной разметки (точечные + коллективные) позволяет решать оба типа задач. Отсутствие пропусков и высокое SNR упрощают предобработку.

Рекомендации:

- Стандартизация (StandardScaler) для моделей, чувствительных к масштабу.
- Сохранение выбросов (это искомые аномалии).
- Канал Pressure сохранить как независимый признак.

3. ПЕРВИЧНЫЙ АНАЛИЗ НАБОРА ДАННЫХ С ИЗОБРАЖЕНИЯМИ

3.1. Постановка задачи

В рамках данного раздела решается задача компьютерного зрения в предметной области сельского хозяйства (точное земледелие).

Описание задачи:

Задача заключается в детекция объектов. Модель должна одновременно находить на изображении каждый помидор и классифицировать его по двум признакам: размеру (обычный / черри) и стадии созревания (зеленый, полусозревший, полностью созревший).

Входными данными являются цветные фотографии кустов томатов, сделанные в теплице местной фермы с помощью двух камер разного разрешения.

Выходными данными (желаемый результат модели) являются для каждого обнаруженного помидора на изображении модель должна вернуть ограничивающий прямоугольник или контур (маску) и метку класса из шести возможных: `b_fully_ripened`, `b_half_ripened`, `b_green`, `l_fully_ripened`, `l_half_ripened`, `l_green`, где `b` означает обычный размер, а `l` – маленький, черри.

Практическая значимость решения данной задачи заключается в автоматизации процессов в тепличном хозяйстве:

- автоматический сбор только созревших плодов;
- прогнозирование урожайности на основе анализа стадий созревания;
- выборочное опрыскивание растений в зависимости от степени зрелости плодов;
- контроль климатических параметров для оптимизации созревания;
- контроль качества на линиях сортировки и упаковки.

3.2. Описание выбранного набора данных

Название набора данных: Laboro Tomato. Ссылка на источник: <https://www.kaggle.com/datasets/nexuswho/laboro-tomato>. Автор и дата подготовки: Karthik Vinayan, дата публикации – 2023 г. Данные собирались в

местной фермерской теплице с помощью двух камер с разным разрешением (3024×4032 и 3120×4160 пикселей). Разметка выполнена в форматах COCO и YOLO, что делает датасет готовым для использования с современными фреймворками (mmdetection, YOLO, Detectron2). Каждый помидор размечен вручную с указанием его размера (обычный или черри) и стадии созревания (зеленый, полусозревший, полностью созревший).

Данный набор данных был выбран, так как он оптимально подходит для решения поставленной задачи по следующим причинам:

- высокое качество и детальность разметки (шесть четко определенных классов, полное покрытие объектов);
- достаточное количество размеченных объектов (всего 9777 bounding box в train и test);
- разнообразие: два размера плодов, три стадии зрелости, разные ракурсы съемки, разное разрешение камер;
- наличие готового бейзлайна (Mask R–CNN с AP 64.3), что позволяет оценить достижимое качество;
- лицензия позволяет академическое использование.

Структура и объем данных: общее количество изображений – 804, из которых 643 отведены на обучение (train) и 161 на тестирование (test).

В табл. 13 представлено распределение изображений по выборкам.

Таблица 13. Распределение изображений и объектов по выборкам

Выборка	Количество изображений	Количество размеченных объектов
train	643	7781
test	161	1996
Всего	804	9777

Распределение объектов по шести классам в обучающей и тестовой выборках приведено в табл. 14.

Таблица 14. Распределение аннотированных объектов по классам

Класс	Описание	Количество (train)	Количество (test)
b_fully_ripened	Обычный помидор, полностью созревший	348	72
b_half_ripened	Обычный помидор, полусозревший (30–89%)	520	116
b_green	Обычный помидор, зеленый (0–30%)	1467	387
l_fully_ripened	Помидор черри, полностью созревший	982	269
l_half_ripened	Помидор черри, полусозревший (30–89%)	797	223
l_green	Помидор черри, зеленый (0–30%)	3667	929

Технический формат: изображения в формате JPEG. Разметка предоставлена в двух наиболее распространенных форматах:

- COCO (файлы _annotations.coco.json) – для задач сегментации и детекции;
- YOLO (текстовые файлы с координатами) – для задач детекции.

Примеры изображений и разметки представлены на рис. 17 и рис. 18.



Рисунок 17. Примеры исходных изображений из датасета (разные стадии созревания и размеры плодов)




Рисунок 18. Примеры размеченных изображений
(визуализация bounding box или масок)

Качество аннотаций: правила разметки четко формализованы (процент красного цвета для определения стадии зрелости). Разметка выполнена вручную, все объекты на изображениях (все видимые помидоры) промаркированы. Проверка 5–10% аннотаций показывает высокое качество: объекты не пропущены, классы соответствуют визуальному состоянию плодов, границы прямоугольников плотно облегают плоды.

Возможные незначительные ошибки в определении стадии на границе допустимы и не критичны для обучения.

Датасет имеет открытую лицензию, разрешающую некоммерческое академическое использование. Изображения получены на частной ферме и не содержат персональных данных (лиц людей, номеров техники). Медицинских или конфиденциальных данных нет.

3.3. Результаты первичного анализа данных с изображениями

3.3.1. Визуализация распределения объектов по классам

Для оценки сбалансированности датасета были построены диаграммы распределения аннотированных объектов по шести классам. На рис. 19 представлено распределение для обучающей выборки.




Рисунок 19. Распределение объектов по классам в обучающей выборке

На основе рис. 19 можно сделать следующие выводы. Наблюдается значительный дисбаланс классов: класс l_green (черри зеленые) доминирует с 3667 объектами, в то время как класс b_fully_ripened (обычные полностью созревшие) представлен всего 348 объектами. Разница составляет более чем в 10 раз. Это является проблемой, так как модель может научиться плохо распознавать редкие классы (b_fully_ripened, b_half_ripened). Рекомендуется применять методы балансировки (аугментация редких классов, взвешивание функции потерь).

На рис. 20 представлено распределение классов в тестовой выборке.




Рисунок 20. Распределение объектов по классам в тестовой выборке (test)

Структура дисбаланса в тестовой выборке аналогична обучающей, что корректно для оценки качества модели.

3.3.2. Анализ пространственного расположения объектов

Для понимания того, в каких областях кадра чаще всего располагаются помидоры, был проведен анализ пространственного распределения центров всех bounding box из обучающей выборки. Изображение было разделено на 9 равных зон: три по горизонтали (левая треть, центр, правая треть) и три по вертикали (верхняя треть, центр, нижняя треть). Для каждого из 7781 объектов определена зона, в которую попадает его центр. Результаты представлены в табл. 15.

Таблица 15. Распределение объектов по зонам изображения

Зона	Количество объектов	Доля, %
верх–лево	438	5,6
верх–центр	578	7,4
верх–право	509	6,5
центр–лево	1067	13,7
центр–центр	2110	27,1
центр–право	696	8,9
низ–лево	681	8,8
низ–центр	1268	16,3
низ–право	434	5,6
Всего	7781	100,0

В табл. 16 представлено распределение по горизонтальной и вертикальной осям.

Таблица 16. Распределение объектов по осям

Ось	Левая треть	Центральная треть	Правая треть
Горизонталь (X)	2186 (28,1%)	3956 (50,8%)	1639 (21,1%)
	Верхняя треть	Центральная треть	Нижняя треть
Вертикаль (Y)	1525 (19,6%)	3873 (49,8%)	2383 (30,6%)

Для визуальной оценки пространственного распределения построена тепловая карта (heatmap), представленная на рис. 21.




Рисунок 21. Тепловая карта расположения помидоров на изображениях

На основе проведенного анализа можно сделать следующие выводы:

- Центральная концентрация. Более половины всех объектов (50,8% по горизонтали и 49,8% по вертикали) располагаются в центральной трети изображения. Зона «центр–центр» содержит 27,1% всех объектов – более четверти от общего числа. Это объясняется тем, что при съемке камера направлена непосредственно на куст с плодами.
- Смещение в левую часть. Левая треть изображения содержит 28,1% объектов, тогда как правая – только 21,1%. Асимметрия может быть связана с особенностями расположения камеры.
- Смещение в нижнюю часть. Нижняя треть кадра содержит 30,6% объектов, верхняя – только 19,6%. Это характерно для съемки кустов томатов, где плоды преимущественно свисают вниз и располагаются в нижней части кадра.
- Неравномерность распределения. Тепловая карта подтверждает, что распределение объектов неравномерно. Наиболее яркие области

сосредоточены в центре и нижней части кадра. Это следует учитывать при обучении модели: неравномерное распределение объектов может привести к тому, что модель будет хуже детектировать помидоры у краев изображения.

- Рекомендации по аугментации. Для компенсации неравномерности рекомендуется при обучении применять аугментации, смещающие объекты к краям кадра (например, случайное кадрирование, сдвиги), чтобы модель обучалась находить помидоры в любой части изображения.

3.3.4. Анализ размера и разрешения изображений

Для оценки геометрических характеристик объектов в датасете был проведен анализ размеров ограничивающих прямоугольников (bounding box). Значения нормализованы относительно размера изображения (диапазон от 0 до 1, где 1 – полный размер изображения). Для наглядности выполнен пересчет в пиксели для типичного разрешения 3024×4032 пикселей.

В табл. 17 представлены сводные статистики размеров bounding box для всех 7781 объектов обучающей выборки.

Таблица 17. Статистика размеров bounding box (обучающая выборка)

Параметр	Минимум	Максимум	Среднее
Ширина (норм.)	0,0079	0,5474	0,1158
Высота (норм.)	0,0055	0,4206	0,0903
Площадь (норм.)	<0,0001	0,2215	0,0142

В табл. 18 приведены сводные статистики размеров bounding box в пикселях.

Таблица 18. Размеры bounding box в пикселях (для разрешения 3024×4032)

Размер	Ширина × Высота, пиксели
Средний	350 × 364
Минимальный	24 × 22
Максимальный	1655 × 1696

Все изображения имеют высокое разрешение: 3024×4032 или 3120×4160 пикселей. Это значительно превышает минимальное требование (512×512) и

является преимуществом для задач детекции мелких объектов (помидоры черри могут быть небольшими на общем плане куста). Однако такое высокое разрешение требует значительных вычислительных ресурсов. Перед обучением модели изображения необходимо масштабировать (случайное изменение масштаба) или использовать метод патчей (деление фото на небольшие фрагменты).

Размеры объектов варьируются от 24×22 до 1655×1696 пикселей (разница в 60+ раз). При масштабировании до 640×640 минимальные объекты сожмутся до 5×4 пикселей – необходимо входное разрешение не менее 1024×1024 .

3.3.5. Примеры визуализации разметки

На рис. 22 приведены примеры корректно размеченных изображений с визуализацией bounding box (желтые прямоугольники) и меток классов. Визуальный контроль подтверждает, что разметка выполнена аккуратно: все видимые помидоры обведены, классы соответствуют визуальному состоянию (например, красные плоды отмечены как `b_fully`). Пропущенных объектов не обнаружено.



Рисунок 22. Визуализация аннотаций: разные стадии зрелости

3.3.6. Оценка качества аннотаций

Для оценки качества аннотаций была проанализирована случайная выборка из 50 изображений (около 6% от общего числа). Типичные ошибки не выявлены. Разметка плотно облегает плоды, классы назначены корректно в

соответствии с процентом красного цвета на плоде. Можно заключить, что аннотации имеют высокое качество и пригодны для обучения модели без дополнительной корректировки.

3.3.7. Рекомендуемая архитектура нейронной сети для детекции

Для решения задачи детекции помидоров рекомендуется использовать архитектуру YOLOv8 – современную одноэтапную модель детекции объектов, разработанную компанией Ultralytics. Выбор обоснован следующими преимуществами:

- Высокая скорость и точность. YOLOv8 показывает результаты, сравнимые с двухэтапными детекторами (Faster R-CNN), при значительно более высокой скорости обработки.
- Встроенная поддержка мелких объектов. Модель использует Feature Pyramid Network (FPN) для выделения признаков на разных масштабах, что критически важно для детекции помидоров черри.
- Готовая реализация. Библиотека ultralytics предоставляет простой API для загрузки предобученных весов (на датасете COCO) и дообучения на собственном датасете.
- Совместимость с форматом разметки. Датасет Laboro Tomato уже содержит аннотации в формате YOLO, что исключает необходимость конвертации.

Выводы по третьему разделу

Краткая характеристика набора данных: задачи детекция и сегментация объектов, объем 804 изображения, 9777 размеченных объектов, количество классов: 6 (размер и стадия созревания), источник открытый датасет Kaggle.

Выявленные особенности и проблемы:

- сильный дисбаланс классов (класс l_green в 10+ раз превышает b_fully_ripened);
- высокое разрешение изображений, требующее ресурсоемкой предобработки;

- Более половины всех объектов (50,8% по горизонтали и 49,8% по вертикали) располагаются в центральных третях изображения, может привести к тому, что модель будет хуже детектировать помидоры у краев изображения.

- отсутствие валидационной выборки (разделение только train/test).

Пригодность данных для решения поставленной задачи:

Данные пригодны для обучения модели детекции и сегментации помидоров по стадиям зрелости и размеру. Однако из-за дисбаланса классов модель может показывать низкое качество на редких классах (b_fully_ripened, b_half_ripened).

Рекомендации по предварительной обработке и обучению:

- Балансировка классов – обязательно применить методы борьбы с дисбалансом:

- Аугментация изображений для редких классов (повороты, масштабирование, изменение яркости);

- Дублирование изображений с редкими объектами.

- Предобработка изображений – масштабирование до размера, приемлемого для GPU (например, 1024×1024) с сохранением пропорций.

- Выбор модели – рекомендуется использовать предобученную на COCO модель (например YOLOv8) и дообучить на Laboro Tomato. Предложенный авторами бейзлайн (Mask R-CNN, AP 64.3) подтверждает, что задача решается с хорошим качеством.

- Контроль переобучения – из-за дисбаланса и небольшого абсолютного числа редких классов следует использовать раннюю остановку и аугментацию.

4. ПЕРВИЧНЫЙ АНАЛИЗ НАБОРА ТЕКСТОВЫХ ДАННЫХ

4.1. Постановка задачи

Выбранный набор данных BBC Full Text Document Classification предназначен для решения задачи классификации текстов в области обработки естественного языка (NLP).

Задача заключается в автоматическом определении категории новостной статьи по ее тексту (многоклассовая классификация).

Входными данными являются полные тексты новостных статей BBC на английском языке.

Выходными данными (целевым признаком) выступает метка категории: business (бизнес), entertainment (развлечения), politics (политика), sport (спорт), tech (технологии).

Предметной областью является обработка естественного языка и классификация новостного контента.

Практическая значимость включает автоматическую рубрикацию новостей, фильтрацию контента, построение рекомендательных систем для читателей.

4.2. Описание выбранного набора данных

Набора данных носит название BBC Full Text Document Classification. Ссылка на источник: <https://www.kaggle.com/datasets/alfatherry/bbc-full-text-document-classification>. Автором является Al Fath Terry, дата публикации – 2023 г. Данные собраны из реальных новостных статей BBC и из открытых источников. Разметка выполнена по пяти категориям на основе тематики статей.

Данный датасет был выбран, так как сбалансирован по классам (по ~400–500 статей на категорию), содержит 2 225 полных текстов на английском языке, имеет четкую структуру (CSV с колонками «data» и «labels»), открытую лицензию, достаточный объем для демонстрации всех этапов анализа текстов.

Распределение по категориям представлено в табл. 19.

Таблица 19. Распределение текстов по категориям

Категория	Количество	Доля, %
sport	511	23,0
business	510	22,9
politics	417	18,7
tech	401	18,0
entertainment	386	17,4
Всего	2 225	100,0

Технический формат: CSV, кодировка UTF–8. Пропуски отсутствуют.

Юридические ограничения: датасет имеет открытую лицензию, персональные данные отсутствуют

4.3. Описание результатов первичного анализа

4.3.1. Загрузка и первичное знакомство

Данные загружены из файла CSV. Общий объем: 2 225 строк, 2 столбца (data – текст статьи, labels – категория). Тексты представлены на английском языке, длина варьируется от коротких новостных заметок до развернутых статей. Категории распределены равномерно: sport – 511, business – 510, politics – 417, tech – 401, entertainment – 386.

4.3.2. Очистка текста

Выполнена предварительная очистка текстов: приведение к нижнему регистру, удаление цифр, знаков препинания, HTML–сущностей и лишних пробелов. В среднем удалено 4,0% символов (201 153 из 5 033 391). Средняя длина текста до очистки 2262, после очистки 2172 символа.

Очистка позволила избавиться от шума (специальные символы, числа), не несущего смысловой нагрузки для классификации

4.3.3. Лемматизация

Выполнена лемматизация – приведение слов к словарной форме (например, «musicians» – «musician», «groups» – «group») с использованием WordNetLemmatizer из библиотеки NLTK. На текстах (839 731 слов) изменили форму 86 509 слова (10.3%).

Лемматизация позволила сократить словарное разнообразие: разные формы одного слова теперь представлены единой леммой, что улучшает качество дальнейшего анализа.

4.3.4. Подсчет частоты слов

После лемматизации выполнен подсчет наиболее часто встречающихся слов. На рис. 23 представлен столбчатый график топ–10 слов.




Рисунок 23. Топ–10 самых частых слов

На рис. 24 представлено облако слов для визуального восприятия частотности.



Рисунок 24. Облако слов

Наиболее частотные слова: the, to, a, of, in, and, it, is, for, that. Преобладание артиклей и предлогов ожидаемо, так как это служебные части речи, которые будут удалены на следующем этапе (стоп-слова).

4.3.5. Удаление стоп-слов

Удалены стоп-слова (предлоги, артикли, местоимения: the, a, is, at, which, и др.) с использованием списка NLTK. Удалено около 42% слов. Среднее количество значимых слов на текст сократилось с 321 до 187.

Удаление стоп-слов позволило оставить только содержательные слова, несущие смысловую нагрузку.

4.3.6. Вычисление TF-IDF

Вычислены значения TF-IDF для оценки важности слов в корпусе. В табл. 20 представлены 20 наиболее значимых слов.

Таблица 20. Топ-20 слов по TF-IDF

№	Слово	TF-IDF
1	said	86,47
2	year	45,70
3	game	37,55
4	film	37,06
5	people	37,05
6	new	35,02
7	government	28,97
8	world	27,66
9	time	27,59
10	company	26,74
11	labour	26,45
12	say	26,37
13	firm	25,48
14	best	25,46
15	election	24,62
16	party	23,91
17	player	23,57
18	sale	23,34
19	number	22,79
20	service	22,75

Наиболее весомые слова: said (86,47), year (45,70), game (37,55), film (37,06), people (37,05). Слово said лидирует, так как используется в новостных статьях при цитировании. Слова game, player, film отражают спортивную и развлекательную тематику.

Слова government, election, labour, party представляют политический блок. Слова company, sale, firm, service относятся к бизнес-категории. Таким образом, TF-IDF успешно выделяет ключевые слова по всем пяти категориям датасета.

4.3.7. Информационный поиск по корпусу

Реализован поиск документов с использованием векторного представления текстов: каждый документ и поисковый запрос преобразуются в TF-IDF-вектор, после чего вычисляется сходство между вектором запроса и векторами всех документов корпуса.

Для запроса «stock market economy» все 5 найденных документов относятся к категории business. Максимальное сходство составило 0,305.

Для запроса «film music award actor oscar album song band» все 5 результатов относятся к категории entertainment. Максимальное сходство – 0,354.

Результаты демонстрируют, что векторное представление TF-IDF успешно определяет тематическую близость текстов и может использоваться для информационного поиска по корпусу новостей.

Выводы по четвертому разделу

В результате первичного анализа набора текстовых данных BBC Full Text Document Classification получены следующие результаты, представлены в табл. 21.

- Пригодность: датасет полностью готов к решению задачи классификации новостей.
- 2 225 статей равномерно распределены по пяти категориям – бизнес, спорт, политика, технологии и развлечения.

- В данных нет пропусков, тексты представлены в машиночитаемом формате CSV.
- Очистка и лемматизация сократили словарный шум, удаление стоп-слов убрало бесполезные для классификации служебные слова, оставив только значимые термины.
- TF–IDF–векторизация позволила выделить ключевые слова по каждой теме: game и player для спорта, government и election для политики, company и sale для бизнеса.
- Информационный поиск на основе векторного представления показал высокую точность, система находит статьи по запросу, даже если запрос не совпадает дословно с текстом.

Таблица 21. Результаты первичного анализа

Параметр	Результат
Объем	2 225 текстов
Категорий	5 (сбалансированы)
Пропуски	Отсутствуют
Средняя длина текста	2 262 символа
Доля измененных слов (лемматизация)	10,3%
Доля удаленных слов (стоп-слова)	~42%

Рекомендации:

- Использовать TF–IDF–векторы в качестве признаков для обучения классификатора – они хорошо разделяют темы даже для коротких запросов.
- В качестве базовой модели взять логистическую регрессию (самый простой классификатор, считает вес слов и решает, к какой категории отнести текст) или Random Forest (множество деревьев решений, каждое из которых определяет, относится ли слово к определенной категории) – они просты, быстро обучаются и не требуют мощного GPU.
- Для повышения точности на длинных и сложных текстах рассмотреть трансформерные модели BERT, RoBERTa, которые понимают текст почти как человек, по контексту.

ЗАКЛЮЧЕНИЕ

В рамках курсового проекта выполнен поиск и первичный анализ наборов данных разных типов по различным областям применения. В ходе выполнения работы были получены следующие основные результаты:

1) подготовлено для каждого типа данных (табличные данные, временные ряды, изображения, тексты) краткое описание выбранной задачи, решение которой связано с применением технологий искусственного интеллекта;

2) подобран и обоснован выбор для каждого типа данных набор данных из авторитетных открытых источников, необходимый для обучения ИИ-модели, решающей соответствующую выбранную задачу;

3) реализован комплекс программ на языке Python, каждая из которых для заданного типа данных выполняет основные функции первичного анализа;

4) сформулированы выводы по каждому этапу анализа, а также итоговое заключение о качестве данных и их пригодности для решения поставленной задачи;

5) размещен исходный код в репозитории системы контроля версий Git: https://github.com/KaKTyZV/KYRSOVAIA_RABOTA.git.

ЛИТЕРАТУРА

1. Barata C., Rotemberg V., Codella N.C.F., et al. A reinforcement learning model for AI-based decision support in skin cancer // Nat Med. 2023. Vol. 29. P. 1941–1946. DOI: 10.1038/s41591-023-02475-5
2. Sezer O.B., Gudelek M.U., Ozbayoglu A.M. Financial time series forecasting with deep learning: A systematic literature review: 2005–2019 // Applied Soft Computing. 2020. Vol. 90. Article 106181. DOI: 10.1016/j.asoc.2020.106181
3. Yurtsever E., Lambert J., Carballo A., Takeda K. A survey of autonomous driving: Common practices and emerging technologies // IEEE Access. 2020. Vol. 8. P. 58443–58469. DOI: 10.1109/ACCESS.2020.2983149
4. Dogan A., Birant D. Machine learning and data mining in manufacturing // Expert Systems with Applications. 2021. Vol. 166. Article 114060. DOI: 10.1016/j.eswa.2020.114060
5. Mohammed S., Budach L., Feuerpfeil M., et al. The effects of data quality on machine learning performance on tabular data // Information Systems. 2025. Vol. 132. P. 102549. DOI: 10.1016/j.is.2025.102549
6. Набор табличных данных Sleep, Screen Time and Stress Analysis. URL: <https://www.kaggle.com/datasets/jayjoshi37/sleep-screen-time-and-stress-analysis>.
7. Набор данных с временными рядами SKAB – Skoltech Anomaly Benchmark. URL: <https://www.kaggle.com/datasets/yuriykatser/skoltech-anomaly-benchmark-skab>.
8. Набор данных с изображениями Laboro Tomato. URL: <https://www.kaggle.com/datasets/nexuswho/laboro-tomato>.
9. Набор текстовых данных BBC Full Text Document Classification. URL: <https://www.kaggle.com/datasets/alfathterry/bbc-full-text-document-classification>