

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное учреждение высшего образования
«Южно–Уральский государственный университет (национальный исследовательский университет)»
Институт естественных и точных наук
Центр «ВиртУм»

Поиск и первичный анализ наборов данных по различным областям применения

09.03.04 «Программная инженерия»

Научный руководитель:
к.ф.–м.н., доцент центра «ВиртУм»,
Я. А. Краева

Автор:
студент группы ЕТ–141
В. А. Бобыкин

Челябинск, 2026 г.

Актуальность: необходимость первичного анализа

Технологии искусственного интеллекта применяются в медицине, финансах, транспорте и промышленности. Однако качество работы ИИ–модели напрямую зависит от качества данных, на которых она обучается. Как отмечается в исследовании Sedir Mohammed (2025) на примере данных о клиентах телеком–компании изучено, как дефекты данных влияют на точность прогнозов. Основные выводы:

- Пропуски в данных: при отсутствии более половины значений модель перестаёт работать.
- Ошибки в целевой переменной: при 20% неверных меток точность падает на 10%.
- Нарушение форматов и дубликаты почти не влияют на результат.

В итоге предварительный анализ и оценка качества данных являются обязательным этапом перед построением любой ИИ–модели.

Табличные данные: задача и описание данных

Задача: Прогнозирование уровня стресса, качества сна и умственной усталости по поведенческим факторам (возраст, пол, профессия, экранное время, кофеин, физическая активность, уведомления)



Набор данных:

- **Название, источник:** Sleep, Screen Time and Stress Analysis, Kaggle
- **URL:** <https://www.kaggle.com/datasets/jayjoshi37/sleep-screen-time-and-stress-analysis>
- **Автор:** Jay Joshi, 2026 г.
- **Описание:** синтетические данные о сне, экранном времени и уровне стресса
- **Размерность:** 15 000 объектов, 13 признаков (3 целевых)
- **Целевые признаки:** уровень стресса, качество сна, умственная усталость

Табличные данные: атрибуты

	№	Название	Семантика	Тип	Допустимые значения						
	1	user_id	Уникальный идентификатор	числовой	1–15 000	7	sleep_duration_hours	Длительность сна (ч)	числовой	4–9	
	2	age	Возраст (лет)	числовой	18–59	8	sleep_quality_score	Качество сна (1–10)	целевой	1–10	
	3	gender	Пол	категориальный	Female, Male, Other	9	stress_level	Уровень стресса (1–10)	целевой	1–10	
	4	occupation	Профессия	категориальный	8 значений	10	caffeine_intake_cups	Кофеин (чашек/день)	числовой	0–4	
	5	daily_screen_time_hours	Экранное время (ч)	числовой	1–10	11	physical_activity_minutes	Физ. активность (мин)	числовой	0–119	
	6	phone_usage_before_sleep_minutes	Телефон перед сном (мин)	числовой	0–119	12	notifications_received_per_day	Уведомлений/день	числовой	20–299	
						13	mental_fatigue_score	Умственная усталость (1–10)	целевой	1–10	

Табличные данные: пример

user id	age	gender	occupation	screen time	phone before sleep	sleep duration	sleep quality	stress level	caffeine	activity	notifications	mental fatigue
1	56	Female	Designer	3.26	86	5.31	7.72	3.49	0	35	119	3.57
2	23	Male	Engineer	7.50	45	6.80	2.15	8.20	2	60	200	8.90
3	41	Other	Teacher	5.10	120	7.00	5.00	5.60	1	80	150	5.40
...	...	...	...	...	...	...	...	...	...	...	...	...

Табличные данные: анализ

	Шаг 1 Качество данных	Шаг 2 Корреляционный анализ	Шаг 3. Проверка на диапазоны значений
Результаты	– Отсутствие пропусков и дубликатов; – Выбросы только в признаке качество сна (9 шт., 0.06%).	– Числовые признаки стресс, качество сна, умственная усталость и экранное время имеют сильные корреляции (> 0.75) – Мультиколлинеарности входных признаков нет (< 0.75).	Значительное различие в масштабах признаков: – $18 \leq \text{возраст} \leq 59$; – $0 \leq \text{чашки_кофе} \leq 4$; – $20 \leq \text{уведомления} \leq 299$.
Действия	– Оставить выбросы как экстремальные случаи	– Использовать все признаки для построения ИИ-модели	– Применить StandardScaler, для приведения всех числовых признаков к единому масштабу

Табличные данные: анализ

Шаг 4. Распределения
числовых атрибутов

Шаг 5. Распределения
категор. атрибутов

Шаг 6. Кодирование
категор. атрибутов

Результаты

- Качество сна: близко к нормальному;
- Уровень стресса и умственная усталость: левосторонняя асимметрия;
- Кофеин: дискретное;
- Остальные признаки: равномерное.

- Пол: дисбаланс;
- Профессия: равномерное.

- Пол: Female, Male, Other. {0, 2}
- Профессия: 8 категорий {0, 7}

Действия

- Уровень стресса и умственная усталость: группировка редких значений

- Пол: учет дисбаланса при обучении модели (увеличить вес категории)

- Label Encoding

Табличные данные: выводы


- Набор данных полностью пригоден для прогнозирования уровня стресса, качества сна и умственной усталости.
- Пропуски и дубликаты отсутствуют, выбросы единичны, категории почти сбалансированы, нужно учесть дисбаланс пола при обучении.
- Данные не требуют трудоёмкой предварительной очистки.
- Единственное ограничение синтетическая природа данных, которая может затруднить перенос результатов на реальные данные.

Временные ряды: задача и описание данных

Задача: Обнаружение аномалий (точечных выбросов и коллективных изменений режима) в работе насосной системы по показаниям датчиков

Набор данных:

- **Название, источник:** SKAB (Skoltech Anomaly Benchmark) v0.9, Kaggle
- **URL:** <https://www.kaggle.com/datasets/yuriykatser/skoltech-anomaly-benchmark-skab>
- **Авторы:** Iurii D. Katser, Vyacheslav O. Kozitsin (Сколтех), 2020 г.
- **Описание:** показания 8 датчиков с испытательного стенда насоса
- **Размерность:** 46 860 строк, 8 каналов, 35 экспериментов
- **Целевые признаки:** anomaly (точечная аномалия), changepoint (смена режима)




Временные ряды: атрибуты

№	Название	Семантика	Тип	Ед. изм.							
1	Accelerometer1 RMS	Виброускорение, датчик 1	числовой	g		6	Thermocouple	Температура жидкости в контуре	числовой	°C	
2	Accelerometer2 RMS	Виброускорение, датчик 2	числовой	g		7	Voltage	Напряжение на двигателе	числовой	В	
3	Current	Ток электродвигателя	числовой	A		8	Volume Flow RateRMS	Скорость потока жидкости	числовой	л/мин	
4	Pressure	Давление после насоса	числовой	бар		9	anomaly	Метка точечной аномалии	целевой	0/1	
5	Temperature	Температура корпуса двигателя	числовой	°C		10	Change point	Метка смены режима	целевой	0/1	

Временные ряды: визуализация

8 измерений



- Accelerometer1RMS, Accelerometer2RMS: резкие скачки при включении насоса – нормальная реакция на запуск двигателя
- Ток: рост тока при включении (до 243 А) – пусковые токи электродвигателя, закономерное явление
- Давление: скачки давления при запуске, отрицательные значения – кавитация при закрытии клапанов (целевая аномалия)
- Температура двигателя: падение температуры за 6 часов – остывание двигателя;
- температура жидкости: падение температуры – остывание жидкости в контуре
- Напряжение: просадки при росте тока – реакция на нагрузку; стабильно при выключенном насосе
- Скорость потока: не стабилен при включении и выключении насоса; в работе стабилен – циклический режим работы насоса

Временные ряды: анализ

Шаг 1 Качество данных

Шаг 2 Корреляционный анализ

Шаг 3. Проверка на диапазоны значений

Результаты

- Пропуски отсутствуют
- Выбросы есть в Accelerometer1RMS (2.67%) и Accelerometer2RMS(2.62%)
- Выбросы отсутствуют в Temperature, Thermocouple, Volume Flow Rate
- В остальных каналах (< 0.2%)

- 9 пар с $r > 0.7$
- Accelerometer1RMS – Accelerometer2RMS: 0.996
- Temperature – Volume Flow RateRMS: 0.902
- Давление не зависит от других ($r < 0.11$)

- Значительное различие в масштабах измерений: от 0.026 (Accelerometer1RMS) до 254.74 (Voltage)
- Различие в 352 раза
- Разные единицы: g, A, бар, °C, В, л/мин

Действия

- Выбросы сохранить – это пиковые вибрации при включении, нормальное поведение системы

- Сократить дублирующие каналы ($r > 0.9$)
- Давление сохранить как уникальный признак

- Применить StandardScaler, для приведения всех числовых признаков к единому масштабу

Временные ряды: анализ

Шаг 4. Распределения измерений

Шаг 5. Разложение на компоненты (декомпозиция)

Шаг 6. Поиск и анализ шумов

Результаты

Мультимодальное распределение:

- Accelerometer1, Accelerometer2,
- Current, Pressure, Voltage,
- Volume Flow RateRMS

Ассиметричное распределение:

- Temperature, Thermocouple

- Тренд: падающий (-8.17°C за 6 часов)
- Сезонность: ~ 60 сек (циклы насоса), амплитуда низкая
- Нестационарный ряд (есть тренд и сезонность)

- $\text{SNR} = 21.11$ дБ – Отлично
- Распределение остатков близко к нормальному
- Шум случаен

Действия

- Учитывать асимметрию при выборе модели
- Использование метрики MAE (средняя абсолютная ошибка)

- Для ARIMA – берем разность, чтобы убрать общий спад или рост
- Для нейросетей – разность не нужна

- Фильтрация не требуется
- Данные чистые

Временные ряды: выводы

- Данные полностью пригодны для задачи поиска аномалий в работе насосного оборудования.
- Пропуски в измерительных каналах отсутствуют, выбросы являются целевыми аномалиями и не подлежат удалению.
- Высокий показатель SNR (21.11 дБ – «Отлично») означает, что шум практически незаметен, данные чистые.

Данные с изображениями: задача и описание данных

Задача: Детекция помидоров на изображении и классификация по двум признакам: размер (обычный/черри) и стадия созревания (зелёный, полусозревший, созревший) всего 6 классов

Набор данных:

- **Название, источник:** Laboro Tomato, Kaggle
- **URL:** <https://www.kaggle.com/datasets/nexuswho/laboro-tomato>
- **Автор:** Karthik Vinayan, 2023 г.
- **Описание:** цветные фотографии кустов томатов из теплицы
- **Размерность:** 804 изображения (643 train / 161 test), 9 777 размеченных объектов
- **Формат разметки:** YOLO и COCO



Данные с изображениями: распределение по классам

Класс	Описание	Train	Test
l_green	Черри, зелёный	3 667	929
b_green	Обычный, зелёный	1 467	387
l_fully_ripened	Черри, созревший	982	269
l_half_ripened	Черри, полусозревший	797	223
b_half_ripened	Обычный, полусозревший	520	116
b_fully_ripened	Обычный, созревший	348	72
Всего		7 781	1 996



Данные с изображениями: анализ

Шаг 1 Качество данных

Шаг 2 Распределение классов

Шаг 3. Размеры объектов

Результаты

- Всего: 804 изображения, 9 777 объектов
- Разметка: YOLO + COCO, выполнена вручную
- Проверка 50 изображений (6%): ошибок и пропусков нет

- l_green (зелёные черри): 47.1%
- b_fully_ripened (созревшие): 4.5%
- **Разница в 10 раз**

- От 24×22 до 1655×1696 пикселей
- Средний: 350×364 пикселя
- **Разница в 60 раз**

Действия

- Данные готовы к обучению
- Дополнительная разметка не требуется

- Аугментация (копии с поворотами и отражениями) редких классов

- Минимальное масштабирование фотографий до 1024×1024 (размер, при котором сохраняется различимость мелких объектов)

Данные с изображениями: анализ

Шаг 4. Пространственное
расположение

Шаг 5.
Архитектура сети

Результаты

- Горизонталь: левая треть(28,1%), центральная треть(50,8%).
- Вертикаль: нижняя треть(30,6%), центральная треть (49,8%)
- Смещение влево и вниз

- YOLOv8 быстрая одноэтапная модель
- FPN для мелких объектов (создаёт несколько уровней изображения для YOLO)

Действия

- Случайное кадрирование (вырезаем случайную часть фото)
- Сдвиги при аугментации

- Обучить модель YOLO на датасете

Данные с изображениями: выводы

- Данные полностью пригодны для задачи детекции помидоров и классификации по размеру и стадии созревания.
- Разметка выполнена качественно: все видимые помидоры обведены, пропущенных объектов нет.
- Основные проблемы, сильный дисбаланс классов (разница в 10 раз) и неравномерное расположение объектов в кадре, решаются стандартными методами аугментации.

Текстовые данные: задача и описание данных

Задача: Автоматическое определение категории новостной статьи по её тексту (многоклассовая классификация)

Набор данных:

- **Название, источник:** BBC Full Text Document Classification, Kaggle
- **URL:** <https://www.kaggle.com/datasets/alfatherry/bbc-full-text-document-classification>
- **Автор:** Al Fath Terry, 2023 г.
- **Описание:** полные тексты новостных статей BBC на английском языке
- **Размерность:** 2 225 текстов, 5 категорий



Текстовые данные: атрибуты

№	Название	Семантика	Тип
1	data	Полный текст новостной статьи BBC	текстовый
2	labels	Категория статьи	категориальный (5 значений)

Текстовые данные: пример

Категория	Текст (первые 100 символов)
business	UK economy facing major risks The UK manufacturing sector will continue to face...
entertainment	Musicians to tackle US red tape Musicians groups are to tackle US visa...
politics	Baron Kinnock makes Lords debut Former Labour leader Neil Kinnock has...
sport	Fuming Robinson blasts officials England coach Andy Robinson insisted he was...
tech	Mobiles rack up 20 years of use Mobile phones in the UK are celebrating...

Текстовые данные: анализ

Шаг 1
Качество данных

Шаг 2
Очистка текста

Шаг 3.
Лемматизация

Результаты

- 2 225 текстов, 5 категорий
- Пропусков нет

- Удалено 201 153 из 5 033 391 символов (4%)
- Средняя длина: до 2 262 после 2 172

Изменили форму 86 509 (10.3%) слов
«musicians» → «musician»

Действия

- Данные загружены без ошибок

- Символы приведены к нижнему регистру
- Удалены цифры, знаки

- Слова приведены к словарной форме

Текстовые данные: анализ

Шаг 4. Подсчёт частоты слов

Шаг 5. Удаление стоп-слов

Шаг 6. Вычисление TF-IDF

Результаты

Популярные слова:

- До очистки: the, to, a, of, and (служебные)
- После очистки стоп-слов: said, year, people, game

- Удалено 41.6% слов
- Среднее: 321 → 187 слов на текст

- Словарь: 27 687 слов
- Топ: said (86.47), game (37.55), film (37.06)

Действия

- Построен график и облако слов

- Убраны the, a, is, at, which и др.

- Выделены ключевые слова по темам

Текстовые данные: выводы

- Датасет полностью готов к решению задачи классификации новостей.
- 2 225 статей равномерно распределены по пяти категориям: бизнес, спорт, политика, технологии и развлечения.
- Пропуски отсутствуют, тексты в машиночитаемом формате CSV.
- Очистка и лемматизация сократили словарный шум, удаление стоп-слов убрало служебные слова, оставив только значимые термины.
- TF-IDF-векторизация позволила выделить ключевые слова по каждой теме.
- Информационный поиск показал высокую точность система находит статьи по запросу.

Основные результаты

1. подготовлено краткое описание выбранной задачи ИИ для каждого типа данных (таблицы, временные ряды, изображения, тексты);
2. подобраны и обоснован выбор наборов данных из открытых источников;
3. реализован комплекс программ на языке Python для первичного анализа;
4. сформулированы рекомендации по предобработке данных;
5. размещен исходный код в Git-репозитории: https://github.com/KaKTyZ/KYRSOVAIA_RABOTA.git.

Анализ табличных данных: пропуски, выбросы и дубликаты



- Пропуски в данных **отсутствуют**
- Дубликаты в данных **отсутствуют**
- Выбросы, найденные методом межквартильного размаха, **присутствуют** в признаке `sleep_quality_score`

Признак	Наличие выбросов	Количество выбросов
age	Нет	0
daily_screen_time_hours	Нет	0
phone_usage_before_sleep_minutes	Нет	0
sleep_duration_hours	Нет	0
sleep_quality_score	Да	9
stress_level	Нет	0
caffeine_intake_cups	Нет	0
physical_activity_minutes	Нет	0
notifications_received_per_day	Нет	0
mental_fatigue_score	Нет	0



Анализ табличных данных: корреляция, диапазоны значений



- Числовые признаки стресс, качество сна, умственная усталость и экранное время имеют **сильные корреляции**
- Мультиколлинеарность входных признаков **отсутствует**



- Масштабы численных признаков **значительно различаются**


Анализ табличных данных: распределения числовых атрибутов

- Качество сна: **близко к нормальному**
- Уровень стресса и умственная усталость: **левосторонняя асимметрия**
- Кофеин: **дискретное**
- Остальные признаки: **равномерное**.




Анализ табличных данных: распределения категор. атрибутов


Пол: дисбаланс



Профессия: равномерное



Анализ табличных данных: группировка risk_group



Условия формирования

Высокий риск:

стресс > 7, качество сна < 5,
экранное время > 8ч

Средний риск:

стресс 4 - 7, качество сна 4 - 7

Низкий риск:

стресс < 4, качество сна > 7

Анализ табличных данных: кодирование

Категориальные признаки

Пол:

{ Male, Female, Other }

Профессия:

{ Manager, Doctor,
Software Engineer, Freelancer,
Student, Researcher,
Designer, Teacher }

Label encoding

Бинарные признаки

Пол:

{ 0, 1, 2 }


Профессия:

{ 0, 1, 2, 3, 4, 5, 6, 7 }

Анализ временных рядов: статистика

Канал	count	mean	std	min	Q1 (25%)	Q2 (50%)	Q3 (75%)	max
Accelerometer1RMS	46860	0,130	0,1261	0,0000	0,027	0,0804	0,215	0,722
Accelerometer2RMS	46860	0,163	0,1442	0,0000	0,040	0,130	0,268	0,800
Current	46860	1,834	6,333	0,355	0,983	1,376	2,484	243,829
Pressure	46860	0,080	0,259	−1,257	0,054	0,054	0,382	1,694
Temperature	46860	79,361	9,404	65,089	69,511	84,975	88,620	95,011
Thermocouple	46860	26,576	2,539	22,020	24,650	25,609	29,157	33,415
Voltage	46860	229,398	12,677	0,580	223,545	229,845	235,923	255,324
Volume Flow RateRMS	46860	75,267	45,839	0,000	32,000	72,021	126,000	133,688

Анализ временных рядов: распределения измерений



Мультимодальное распределение:

Accelerometer1, Accelerometer2,
Current, Pressure, Voltage,
Volume Flow RateRMS


Ассиметричное распределение:

Temperature, Thermocouple


Анализ временных рядов: пропуски и выбросы

- Пропуски в данных **отсутствуют**
- Выбросы, найденные методом межквартильного размаха, присутствуют в измерениях: **Accelerometer1RMS, Accelerometer2RMS, Current, Pressure и Voltage**

Канал	Выбросов	Доля, %
Accelerometer1RMS	1253	2,67
Accelerometer2RMS	1227	2,62
Current	36	0,08
Pressure	65	0,14
Temperature	0	0,00
Thermocouple	0	0,00
Voltage	37	0,08
Volume Flow RateRMS	0	0,00




Анализ табличных данных: корреляция, диапазоны значений




– Масштабы измерений многомерного ряда значительно различаются

– Большинство признаков демонстрируют **сильную корреляцию**, остальные признаки почти не коррелируют




Анализ временных рядов: декомпозиция

Ряд Temperature (сезонность = 1 минута)




Анализ временных рядов: распределения остатков

Нормальное распределение остатков Temperature



Анализ данных с изображениями: распределение классов

Разница в 10 раз между b_fully и l_green



Анализ данных с изображениями: размеры объектов

Значения относительно размера изображения


Параметр	Минимум	Максимум	Среднее
Ширина	0,0079	0,5474	0,1158
Высота	0,0055	0,4206	0,0903
Площадь	<0,0001	0,2215	0,0142

Значения в пикселях

Размер	Ширина × Высота
Средний	350 × 364
Минимальный	24 × 22
Максимальный	1655 × 1696

Анализ данных с изображениями: пространственное расположение

Зона	Количество объектов	Доля, %
верх–лево	438	5,6
верх–центр	578	7,4
верх–право	509	6,5
центр–лево	1067	13,7
центр–центр	2110	27,1
центр–право	696	8,9
низ–лево	681	8,8
низ–центр	1268	16,3
низ–право	434	5,6
Всего	7781	100,0




Анализ текстовых данных: распределение текстов по категориям


Категория	Количество	Доля, %
sport	511	23,0
business	510	22,9
politics	417	18,7
tech	401	18,0
entertainment	386	17,4
Всего	2 225	100,0

Анализ текстовых данных: подсчёт частоты слов

До удаления стоп-слов



После удаления стоп-слов



Анализ текстовых данных: Топ-10 слов по TF-IDF

№	Слово	TF-IDF
1	said	86,47
2	year	45,70
3	game	37,55
4	film	37,06
5	people	37,05
6	new	35,02
7	government	28,97
8	world	27,66
9	time	27,59
10	company	26,74